

Национальный исследовательский университет «Высшая школа экономики»
Факультет экономических наук

Домашняя работа по дисциплине
«Машинное обучение в экономике»

«Как выход на маркетплейсы влияет на выручку малого бизнеса»

Выполнили: Альмяшкин Алексей Васильевич БЭК239, группа 6
Габараев Владислав Витальевич БЭК233, группа 6
Карпенков Всеволод Сергеевич БЭК239, группа 6
Семинарист: Зинченко Дарья Игоревна

Москва, 2026

Оглавление

<i>Раздел 1. Обоснование темы</i>	3
Задание 1.1	3
Задание 1.2	3
Задание 1.3	4
Задание 1.4	5
Задание 1.5	5
Задание 1.6	6
<i>Раздел 2. Генерация и предварительная обработка данных</i>	7
Задание 2.1	7
Задание 2.2	9
Задание 2.3	11
Задание 2.4	11
<i>Раздел 3. Классификация</i>	12
Задание 3.1	12
Задание 3.2	12
Задание 3.3	14
Задание 3.4	16
Задание 3.5	17
Задание 3.6	18
Задание 3.7	18
Задание 3.8	20
Задание 3.9	21
Задание 3.10 (повышенная сложность)	21
<i>Раздел 4. Регрессия</i>	22
Задание 4.1	23
Задание 4.2	23
Задание 4.3	24
Задание 4.4 (повышенная сложность)	25
<i>Раздел 5. Эффекты воздействия</i>	26
Задание 5.1	26
Задание 5.2	26
Задание 5.3	27
Задание 5.4	28
Задание 5.5	29
Задание 5.6	31
Задание 5.7	31
Задание 5.8	32
Задание 5.9	33
<i>Список литературы</i>	36

Раздел 1. Обоснование темы

Задание 1.1

Придумайте непрерывную зависимую (целевую) переменную и эндогенную бинарную переменную воздействия. Обоснуйте, почему переменная воздействия может быть эндогенной и, в соответствии с приведенным обоснованием, создайте хотя бы одну дополнительную ненаблюдаемую переменную, которая коррелирует и с целевой переменной, и с переменной воздействия.

Ответ

В качестве непрерывной целевой переменной рассматривается месячная выручка малого предприятия Revenue (в тыс. руб.). Бинарной переменной воздействия выступает факт подключения предприятия к маркетплейсу MarketplaceAdoption: переменная равна 1, если предприятие продаёт продукцию через маркетплейс, и 0, если не представлено на маркетплейсе.

Переменная воздействия эндогенна, потому что подключение к маркетплейсу - это не случайное событие, а управленческое решение. Предприниматели с более высокими деловыми качествами, склонные к риску, с большей вероятностью выходят на маркетплейсы и одновременно получают более высокую выручку независимо от самого подключения. Возникает самоотбор, при котором наблюдаемая разница в выручке между подключёнными и неподключёнными фирмами отражает не только эффект площадки, но и различия в способностях предпринимателей.

Чтобы формально описать этот механизма вводится ненаблюдаемая переменная предпринимательская способность EntrepreneurialAbility (U). Она положительно коррелирует и с вероятностью подключения, и с выручкой, что и создаёт эндогенность. Переменная U используется при генерации данных, но не включается в наблюдаемый датасет и ни в одну из моделей анализа в качестве признака.

Задание 1.2

Опишите, для чего может быть полезно изучение влияния переменной воздействия на зависимую переменную. В частности, укажите, как эта информация может быть использована бизнесом или государственными органами.

Ответ

Во-первых, оценка влияния подключения к маркетплейсу на выручку имеет прямую практическую значимость для бизнеса. Предпринимателю, рассматривающему выход на платформу, необходимо понимать ожидаемую отдачу от этого шага. Простое сравнение выручки фирм, присутствующих и не присутствующих на маркетплейсах, завышает эффект площадки: ей приписывается результат, который частично объясняется более высокими способностями уже подключившихся предпринимателей. Оценка, очищенная от смещения самоотбора, позволяет принимать решение о подключении на основе реального причинного эффекта.

Во-вторых, в этом заинтересованы государственные органы, разрабатывающие программы цифровизации малого бизнеса. Чтобы обоснованно распределять бюджетные средства, регулятору требуется оценка результативности подобных мер, не искажённая тем, что в программах добровольно участвуют изначально более успешные фирмы. Метод, способный отделить причинный эффект подключения от влияния ненаблюдаемых характеристик, даёт основу для оценки эффективности таких инициатив.

Работа выполняется на синтетических данных, поэтому истинный эффект известен по построению. Это позволяет сопоставить оценки, полученные разными методами, с истинным значением и оценить смещение наивных подходов в условиях эндогенности.

Задание 1.3

Обоснуйте наличие причинно-следственной связи между зависимой переменной и переменной воздействия. Кратко опишите результаты не менее 2 предшествующих исследований из научной литературы, подкрепляющих ваши предположения. Критически оцените методологию этих работ и объясните, в чем преимущества и недостатки применяемых вами методов по сравнению с теми, что использовались в этих исследованиях.

Ответ

Обоснование причинно-следственной связи.

Подключение к маркетплейсу способно увеличивать выручку малого бизнеса по нескольким каналам:

- Платформа расширяет географию продаж и открывает доступ к аудитории, недостижимой через офлайн-каналы.
- Она снижает издержки привлечения клиентов, принимая на себя платёжную инфраструктуру, логистику и механизмы доверия (отзывы, рейтинги).
- Действуют сетевые эффекты: рост числа продавцов и покупателей повышает ценность участия для каждого нового продавца.

Однако, эта связь зашумлена эндогенностью: как показано в пункте 1.1, более способные предприниматели чаще подключаются к маркетплейсам, и их качества одновременно повышают выручку. Задача исследования - отделить эффект самого подключения от влияния ненаблюдаемых способностей.

Предшествующие исследования.

[Zhu & Kraemer \(2005\)](#) анализируют, как внедрение и интенсивность использования систем электронного бизнеса влияют на показатели розничных компаний, опираясь на опрос более 600 фирм из 10 стран. Авторы выделяют несколько уровней интенсивности использования электронного бизнеса и показывают, что более глубокая интеграция цифровых технологий положительно связана с ростом выручки и операционной эффективности; ценность реализуется не столько от факта внедрения, сколько от масштабов и качества использования. Поскольку маркетплейс можно рассматривать как одну из форм электронного бизнеса, этот результат поддерживает гипотезу о его влиянии на выручку розничного бизнеса.

[Ramanathan et al. \(2012\)](#) изучают влияние электронной коммерции на результативность малых и средних предприятий Тайваня. На выборке из 159 производственных и сервисных МСП авторы средствами регрессионного анализа показывают, что использование продаж в интернете статистически значительно улучшает как маркетинговые показатели (рост продаж, расширение клиентской базы), так и операционную эффективность; величина эффекта зависит от типа предприятия и отрасли. Результат непосредственно подкрепляет предположение о положительном влиянии подключения к маркетплейсу на выручку малого бизнеса.

Критическая оценка методологии.

Обе работы опираются на наблюдательные данные и регрессионные методы. [Zhu & Kraemer \(2005\)](#) используют многофакторные регрессии с контролем отраслевых и страновых различий, но не применяют инструментальных переменных или квазиэкспериментальных дизайнов, поэтому не могут исключить смещение от самоотбора: фирмы, изначально более склонные к инновациям, могли активнее внедрять электронный бизнес и одновременно показывать лучшие результаты. [Ramanathan et al. \(2012\)](#) оценивают линейные регрессии на данных одномоментного опроса, что также не позволяет отделить причинный эффект от влияния ненаблюдаемых характеристик (качество менеджмента, цифровая зрелость). Авторы обеих работ признают эти ограничения, но не устраняют эндогенность; кроме того, истинный причинный эффект в их условиях неизвестен, поэтому проверить точность оценок невозможно.

Преимущества и недостатки применяемого подхода.

В работе используется двойное машинное обучение с инструментальной переменной (DML-IV) на синтетических данных. Синтетическая природа данных даёт точное знание истинного эффекта, что позволяет верифицировать оценку и измерить её смещение - возможность, недоступная при работе с реальными данными. Гибкие ML-модели (градиентный бустинг) в составе DML-IV улавливают нелинейные зависимости и взаимодействия без их явного задания исследователем; линейная регрессия способна учитывать нелинейности через полиномы и взаимодействия, но требует корректной априорной спецификации функциональной формы, ошибки в которой ведут к смещению, а избыточное число членов - к переобучению. Ортогонализация и кросс-валидация в DML-IV снижают регуляризационное смещение и обеспечивают состоятельность оценки при валидном инструменте.

Ограничения подхода также следует обозначить. Успешная верификация в контролируемой среде не гарантирует внешней валидности: на реальных данных с более сложными искажениями метод может работать иначе. DML-IV не решает проблему поиска и обоснования инструмента - в симуляции инструмент (PilotVoucher) задаётся валидным по построению, тогда как в эмпирическом исследовании доказательство его экзогенности остаётся трудной задачей. Наконец, работа носит методический характер: она демонстрирует применение причинных ML-методов в условиях эндогенности, но не даёт готовых количественных рекомендаций для конкретного рынка.

Задание 1.4

Придумайте хотя бы 3 контрольные переменные, по крайней мере одна из которых должна быть бинарной и хотя бы одна – непрерывной. Кратко обоснуйте выбор каждой из них.

Ответ

Для ослабления смещения, вызванного общими наблюдаемыми факторами, в модель включаются три контрольные переменные.

1. **Возраст бизнеса** (BusinessAge, непрерывная, лет). Более зрелые компании, как правило, обладают наработанной клиентской базой, устойчивой репутацией и отлаженными процессами, что повышает выручку. Возраст связан и с готовностью осваивать новые каналы сбыта, причём связь нелинейна: склонность к подключению растёт с возрастом, но у наиболее «старых» фирм ослабевает. Пропуск этой переменной привёл бы к смещению оценки эффекта.
2. **Численность сотрудников** (EmployeeCount, количественная, число сотрудников). Размер бизнеса отражает его масштаб и ресурсные возможности: более крупные малые предприятия способны выделить персонал для работы с онлайн-платформой и обычно показывают более высокую выручку. Переменная выступает конфаундером, связывая воздействие и целевую переменную.
3. **Пригодность продукции для онлайн-продаж** (OnlineSuitable, бинарная: 1 - основная продукция хорошо подходит для онлайн-торговли, 0 - требует офлайн-присутствия). Товары вроде одежды, электроники или книг легко продаются через интернет, тогда как свежая выпечка или парикмахерские услуги ограничены в цифровых каналах. Категория продукта определяет и ожидаемую отдачу от подключения, и средний уровень выручки; без её контроля наивное сравнение приписало бы маркетплейсу эффект, обусловленный характером товара.

Задание 1.5

Придумайте бинарную инструментальную переменную и обоснуйте, почему она удовлетворяет необходимым условиям.

Ответ

В качестве бинарного инструмента предлагается переменная PilotVoucher (пилотный ваучер). Она равна 1, если предприятие было случайным образом отобрано для участия в пилотной государственной программе, предоставляющей ваучер на компенсацию комиссии

маркетплейса в первый год, и 0 в противном случае. Отбор проводится методом простой случайной выборки среди малых предприятий, удовлетворяющих базовым критериям (регистрация в реестре МСП, отсутствие предыдущего опыта работы с маркетплейсами).

- **Релевантность.** Ваучер снижает финансовые издержки выхода на платформу и тем самым повышает привлекательность подключения, поэтому он должен положительно влиять на вероятность подключения (MarketplaceAdoption). На сгенерированных данных эта связь проверяется напрямую.
- **Независимость (экзогенность).** Ваучер распределяется случайно, поэтому его получение не связано с предпринимательскими способностями (U) и иными ненаблюдаемыми факторами, влияющими на выручку.
- **Исключение.** Условие исключения выполняется в рамках заданного процесса генерации данных: при фиксированном статусе подключения ваучер не влияет на ценовую политику, объём продаж и выручку предприятия. Его влияние на Revenue проходит только через изменение вероятности MarketplaceAdoption. В уравнение выручки инструмент напрямую не включается. Предполагается, что снижение комиссии не меняет ценовую политику продавца, поэтому ваучер не воздействует на выручку напрямую, а только через изменение вероятности подключения. В процессе генерации данных это условие задано по построению: инструмент не входит в уравнение выручки.

Задание 1.6

В случае необходимости приведите дополнительные содержательные комментарии о целях, задачах, методологии и вкладе вашего исследования.

Ответ

В работе не оценивается фактическое влияние маркетплейсов на конкретном рынке. Данные сгенерированы, поэтому выводы относятся к тому, как разные методы работают в заранее заданной причинной схеме.

В этой схеме специально заложена проблема самоотбора. Предпринимательская способность (U) влияет и на вероятность подключения к маркетплейсу, и на выручку, но в наблюдаемый датасет не включается. Поэтому простое сравнение подключённых и неподключённых предприятий не позволяет понять, связана ли часть разницы в выручке не с маркетплейсом, а с ненаблюдаемыми характеристиками предпринимателей.

Инструмент (PilotVoucher) используется как внешний источник изменения вероятности подключения. Он позволяет проверить, насколько методы с инструментальной переменной помогают отделить эффект самого подключения от самоотбора. Так как при генерации данных известны потенциальные исходы, оценки ATE, CATE и LATE можно сопоставить с истинными значениями.

Поэтому вклад работы состоит не в практической рекомендации для бизнеса или государства, а в демонстрации логики причинного анализа на контролируемом примере. Результаты показывают, почему при наличии скрытой переменной наивные оценки могут быть смещены и зачем в таких задачах нужны инструменты и методы причинного вывода.

Раздел 2. Генерация и предварительная обработка данных

Задание 2.1

Опишите математически предполагаемый вами процесс генерации данных:

- Опишите распределения экзогенных переменных (контрольные переменные, инструмент, ненаблюдаемые факторы) с конкретными параметрами.
- Запишите потенциальные исходы переменной воздействия в зависимости от значения инструмента. Опишите, как они связаны с наблюдаемыми значениями переменной воздействия. Обоснуйте предполагаемые направления связей переменной воздействия с контрольными переменными, ненаблюдаемыми переменными и инструментом.
- Запишите потенциальные исходы зависимой переменной в зависимости от наличия воздействия. Опишите, как они связаны с наблюдаемыми значениями зависимой переменной. Обоснуйте предполагаемые направления связей между зависимой переменной и остальными факторами.

Ответ

2.1.1. Распределения экзогенных переменных

$$Z = \text{PilotVoucher} \sim \text{Bernoulli}(0.5)$$

$$U = \text{EntrepreneurialAbility} \sim \mathcal{N}(0,1)$$

$$\text{BusinessAge} \sim \text{Gamma}(\text{shape} = 2, \text{scale} = 3)$$

$$\text{EmployeeCount} \sim \text{Poisson}(\lambda = 5)$$

$$\text{OnlineSuitable} \sim \text{Bernoulli}(0.6)$$

Все переменные взаимно независимы. Распределения выбирались исходя из содержательной природы переменных, а их параметры заданы как правдоподобные модельные предпосылки, а не оценены по эмпирическим данным. Инструмент *PilotVoucher* и признак *OnlineSuitable* бинарны, поэтому моделируются распределением Бернулли: вероятность 0.5 для ваучера отражает сбалансированный случайный отбор 50/50 в пилотную программу, а 0.6 для *OnlineSuitable* - предположение, что большинство фирм работает с товарами или услугами, в той или иной мере пригодными для онлайн-торговли. Ненаблюдаемая способность *U* задаётся стандартным нормальным распределением: это латентная характеристика без естественной единицы измерения, а стандартизация делает коэффициенты при ней интерпретируемыми в единицах стандартного отклонения. Возраст бизнеса неотрицателен, поэтому для него выбрано гамма-распределение $\text{Gamma}(2, 3)$ (среднее 6 лет, дисперсия 18): оно даёт правостороннюю скошенность, при которой основная масса фирм сосредоточена в области малых возрастов, а немногочисленные старые фирмы образуют длинный правый хвост. Численность сотрудников - счётная неотрицательная величина, для которой естественно пуассоновское распределение со средним 5, что соответствует масштабу малого предприятия.

2.1.2. Модель для переменной воздействия (MarketplaceAdoption)

Подключение к маркетплейсу *D* - управленческое решение, а не случайное событие, и именно его эндогенность составляет суть исследования, поэтому *D* порождается не подбрасыванием монеты, а через явную модель. Эта модель решает три задачи одновременно: зависимость *D* от ненаблюдаемой способности *U* создаёт эндогенность (более способные предприниматели чаще подключаются и одновременно больше зарабатывают); зависимость от инструмента *Z* обеспечивает релевантность инструмента; зависимость от контрольных переменных создаёт наблюдаемый конфаундинг, который контролируется при анализе.

Поскольку D бинарна, она порождается через латентную склонность к подключению D^* - непрерывный индекс ожидаемой выгоды от выхода на платформу - с последующим пороговым правилом. Латентная склонность:

$$D^*(z) = \alpha_0 + \alpha_1 z + \alpha_2 U + \alpha_3 \text{BusinessAge} + \alpha_4 \text{BusinessAge}^2 + \alpha_5 \text{EmployeeCount} + \alpha_6 \text{OnlineSuitable} + \alpha_7 (z \cdot \text{OnlineSuitable}) + \varepsilon_D, \varepsilon_D \sim \mathcal{N}(0,1) \quad (1)$$

Потенциальные исходы воздействия в зависимости от значения инструмента:

$$D(z) = 1\{D^*(Z) > 0\}, \quad z \in 0,1 \quad (2)$$

Наблюдаемое воздействие связано с потенциальными исходами через фактическое значение инструмента:

$$D = ZD(1) + (1 - Z)D(0) = 1\{D^*(Z) > 0\} \quad (3)$$

Поскольку в потенциальных исходах $D(0)$, $D(1)$ и в наблюдаемом D используется один и тот же шок ε_D , наблюдаемое значение в точности совпадает с $D(Z)$. Подчиняющиеся (комплаеры) определяются как фирмы, подключающиеся при наличии ваучера и не подключающиеся без него: $\text{Complier} = 1\{D(1) > D(0)\}$. Пороговая конструкция сразу задаёт корректно определённые потенциальные исходы $D(0)$ и $D(1)$, без которых в разделе 5 невозможно выделить комплаеров и оценить локальный средний эффект (LATE).

Параметры модели воздействия:

$$\alpha_0 = -2.4, \alpha_1 = 1.0, \alpha_2 = 0.8, \alpha_3 = 0.3, \alpha_4 = -0.02, \alpha_5 = 0.1, \alpha_6 = 0.5, \alpha_7 = 0.5$$

Обоснование направлений связей. Коэффициент при инструменте положителен ($\alpha_1 > 0$): ваучер повышает склонность к подключению, что обеспечивает релевантность. Коэффициент при ненаблюдаемой способности положителен ($\alpha_2 > 0$): более способные предприниматели чаще подключаются - это и есть источник эндогенности, поскольку U одновременно повышает выручку. Возраст бизнеса входит нелинейно: линейный член положителен ($\alpha_3 > 0$), а квадратичный отрицателен ($\alpha_4 < 0$), что задаёт вогнутую (с насыщением) зависимость - склонность растёт с возрастом, но у наиболее старых фирм ослабевает. Численность сотрудников ($\alpha_5 > 0$) и пригодность продукции для онлайн-продаж ($\alpha_6 > 0$) повышают склонность к подключению. Взаимодействие ваучера и пригодности продукции положительно ($\alpha_7 > 0$): ваучер сильнее влияет на фирмы с пригодной для онлайн-продукцией, что делает первую ступень гетерогенной. Свободный член $\alpha_0 = -2.4$ подобран так, чтобы доля подключённых фирм составляла около 45%.

При указанных значениях доля подключённых бизнесов в симуляции равна примерно 44.8%.

2.1.3. Модель для зависимой переменной (Revenue)

Месячная выручка (в тыс. руб.) моделируется как логнормальная величина. Логарифм выручки в отсутствие подключения задаётся линейным уравнением с нормальной ошибкой:

$$\ln Y(0) = \beta_0 + \beta_1 \text{BusinessAge} + \beta_2 \text{EmployeeCount} + \beta_3 \text{OnlineSuitable} + \beta_4 U + \varepsilon_Y, \quad \varepsilon_Y \sim \mathcal{N}(0, \sigma_Y^2) \quad (4)$$

Эффект подключения гетерогенен и зависит от пригодности продукции и от способностей предпринимателя:

$$\tau = \gamma_0 + \gamma_1 \text{OnlineSuitable} + \gamma_2 U \quad (5)$$

Потенциальные исходы выручки различаются мультипликативным множителем e^τ :

$$Y(0) = \exp \ln Y(0), \quad Y(1) = \exp \ln Y(0) + \tau$$

Наблюдаемая выручка определяется фактическим значением воздействия:

$$Y = DY(1) + (1 - D)Y(0) \quad (6)$$

Выбор логнормального распределения обусловлен тем, что выручка строго положительна и сильно скошена вправо: у большинства фирм она умеренная, у немногих - очень высокая. В логарифмической шкале эффекты становятся мультипликативными (процентными), а не аддитивными: базовый эффект подключения интерпретируется как процентный прирост выручки $[e^{\gamma_0} - 1] \times 100\% \approx 35\%$, а коэффициенты при количественных регрессорах - как полуэластичности. Аддитивный шум в логарифмах соответствует мультипликативному шуму в уровнях, что отражает разброс выручки между фирмами.

Параметры модели выручки:

$$\beta_0 = 4.5, \quad \beta_1 = 0.05, \quad \beta_2 = 0.08, \quad \beta_3 = 0.2, \quad \beta_4 = 0.4, \quad \gamma_0 = 0.3, \quad \gamma_1 = 0.2,$$

$$\gamma_2 = 0.2, \quad \sigma_Y = 0.4$$

Обоснование направлений связей. Все коэффициенты при характеристиках фирмы положительны: возраст ($\beta_1 > 0$), численность сотрудников ($\beta_2 > 0$) и пригодность продукции для онлайн ($\beta_3 > 0$) повышают выручку. Способность предпринимателя положительно влияет на выручку ($\beta_4 > 0$) и одновременно входит в уравнение склонности к подключению - именно это двойное присутствие U создаёт эндогенность. Базовый эффект подключения положителен ($\gamma_0 > 0$); он усиливается для фирм с пригодной для онлайн продукцией ($\gamma_1 > 0$) и для более способных предпринимателей ($\gamma_2 > 0$). Зависимость эффекта τ от U означает, что величина выгоды от подключения коррелирует с ненаблюдаемой способностью, поэтому наивные оценки эффекта смещены. Истинные потенциальные исходы $Y(0)$ и $Y(1)$, сохранённые при генерации, позволяют вычислить настоящие средний и условные средние эффекты и тем самым верифицировать оценки, полученные по наблюдаемым данным.

При указанных параметрах базовая выручка (при нулевых характеристиках и отсутствии подключения) равна $e^{4.5} \approx 90.0$ тыс. руб. В симуляции средняя наблюдаемая выручка составляет около 369 тыс. руб., медианная - около 244 тыс. руб.; правосторонняя асимметрия (среднее выше медианы) типична для финансовых показателей и соответствует масштабу малого бизнеса.

Задание 2.2

Симулируйте данные в соответствии с предполагаемым вами процессом и приведите корреляционную матрицу, а также таблицу со следующими описательными статистиками:

- Для непрерывных переменных: выборочное среднее, выборочное стандартное отклонение, медиана, минимум и максимум.
- Для бинарных переменных: доля и количество единиц.

Ответ

На основе описанной модели сгенерировано $n = 2000$ наблюдений. Наблюдаемый датасет `observed_df` содержит переменные `Revenue`, `MarketplaceAdoption`, `PilotVoucher`, `BusinessAge`, `EmployeeCount` и `OnlineSuitable`. Ненаблюдаемая способность U , потенциальные исходы и индикатор комплаеров сохранены отдельно в `full_df` для анализа эффектов воздействия в Разделе 5. Корреляционная матрица наблюдаемых переменных представлена на Рисунке 1.




Рисунок 1. Корреляционная матрица наблюдаемых переменных

Интерпретация.

Наибольшая корреляция наблюдается между Revenue и MarketplaceAdoption ($r \approx 0.47$), что согласуется с гипотезой о положительном эффекте, но не является чрезмерной, отражая присутствие шума и ненаблюдаемой переменной. Инструмент PilotVoucher умеренно коррелирует с воздействием ($r \approx 0.28$), что подтверждает его релевантность, и практически не коррелирует ни с выручкой, ни с контрольными переменными ($|r| \leq 0.05$), что свидетельствует о выполнении условия экзогенности. Связи между контрольными переменными крайне слабы (максимальная корреляция 0.037), мультиколлинеарность отсутствует, что ожидаемо при независимой генерации.

	Revenue	BusinessAge	EmployeeCount
Среднее	369.32	5.98	5.07
Ст. откл.	385.61	4.23	2.33
Медиана	243.88	4.97	5.00
Минимум	26.76	0.09	0.00
Максимум	5278.87	34.90	15.00

Таблица 1. Описательные статистики непрерывных переменных

	Доля единиц	Количество единиц
MarketplaceAdoption	0.448	895
PilotVoucher	0.506	1013
OnlineSuitable	0.567	1134

Таблица 2. Описательные статистики бинарных переменных

Все доли бинарных переменных находятся в допустимых пределах (0.1–0.9). Распределение выручки имеет положительную асимметрию (медиана ниже среднего), что типично для финансовых показателей. Масштаб выручки (сотни тысяч рублей в месяц) соответствует реалистичным показателям малого бизнеса. Около 45% предприятий подключены к маркетплейсу, что не создаёт экстремального дисбаланса.

Задание 2.3

Разделите выборку на обучающую и тестовую. Тестовая выборка должна включать от 20% до 30% наблюдений.

Ответ

Выборка случайным образом (с фиксацией `random_state = 42`) разделена на обучающую (75%, 1500 наблюдений) и тестовую (25%, 500 наблюдений) с помощью функции `train_test_split`. Разделение применено к наблюдаемому датафрейму `observed_df`; в обеих частях сохранены целевая переменная (`Revenue`), воздействие (`MarketplaceAdoption`), инструмент (`PilotVoucher`) и контрольные признаки. Обучающая выборка используется для настройки моделей классификации и регрессии, тестовая - для оценки их качества. При оценивании эффектов воздействия (Раздел 5) обучающая и тестовая выборки объединяются в одну.

Задание 2.4

В случае необходимости проведите дополнительный анализ и приведите дополнительные комментарии о процессе генерации данных, описательных статистиках и т.д.

Ответ

Дополнительный анализ не проводился вследствие отсутствия необходимости.

Раздел 3. Классификация

Задание 3.1

Отберите признаки, которые могут быть полезны при прогнозировании переменной воздействия. Не включайте в число этих признаков целевую переменную.

Ответ

В качестве прогнозируемой переменной в задаче классификации выступает факт подключения бизнеса к маркетплейсу - переменная воздействия MarketplaceAdoption (D). В набор признаков были включены четыре наблюдаемые переменные: инструмент PilotVoucher (Z), а также три контрольные переменные - BusinessAge, EmployeeCount и OnlineSuitable.

Выбор именно этих признаков опирается на заложенный процесс генерации данных, в котором каждая из них непосредственно влияет на склонность бизнеса к подключению. Инструмент PilotVoucher снижает издержки выхода на платформу и потому повышает вероятность подключения, обеспечивая наибольшую объясняющую силу среди всех признаков. Переменная OnlineSuitable отражает пригодность продукции для онлайн-торговли и входит в уравнение склонности как напрямую, так и через взаимодействие с инструментом. Численность сотрудников EmployeeCount характеризует ресурсные возможности компании для организации онлайн-продаж, а BusinessAge связан со склонностью к подключению немонотонно: она растёт по мере накопления опыта, но для зрелых фирм выходит на плато и снижается из-за их большей консервативности. Поэтому все четыре признака выбраны не произвольно, а исходя из их роли в процессе генерации данных.

Отдельно отметим, что важность признака не следует отождествлять с его линейной корреляцией с целевой переменной. В частности, переменная BusinessAge имеет близкую к нулю линейную корреляцию с подключением, что обусловлено немонотонным (квадратичным) характером связи; тем не менее нелинейные модели (случайный лес, градиентный бустинг) способны извлечь из неё полезную информацию, поэтому исключать её нецелесообразно (нелинейные зависимости могут быть учтены и регрессионной моделью при правильной спецификации функциональной формы, однако на практике такая спецификация почти никогда не известна заранее).

Из набора признаков сознательно исключены две переменные. Во-первых, целевая переменная исследования - выручка Revenue - не включается в модель в соответствии с условием задания. Кроме того, выручка является следствием подключения к маркетплейсу ($D \rightarrow \text{Revenue}$), а не его причиной, поэтому её использование в качестве предиктора воздействия означало бы обратную причинность и утечку информации из будущего. Во-вторых, ненаблюдаемая переменная EntrepreneurialAbility (U), задействованная при генерации данных для создания эндогенности, не включается в число признаков ни в одной из моделей, как того требует постановка задачи, что воспроизводит реалистичную ситуацию неполноты наблюдаемых данных.

Задание 3.2

Для каждого метода:

- *Оцените точность (ассигасу), используя произвольные значения гиперпараметров на обучающей выборке, тестовой выборке и с помощью кросс-валидации.*
- *С помощью кросс-валидации на обучающей выборке подберите оптимальные значения гиперпараметров.*
- *В одной таблице укажите исходные и подобранные значения гиперпараметров, а также кросс-валидационную точность (ассигасу) и точность на тестовой выборке до и после тюнинга.*
- *Обсудите наличие или отсутствие признаков переобучения модели.*

Проинтерпретируйте полученные результаты.

Повышенная сложность: подберите на обучающей выборке оптимальные значения гиперпараметров случайного леса, ориентируясь на значение OOB (out-of-bag) ошибки. Сопоставьте гиперпараметры и точность на тестовой выборке для случайного леса в зависимости от того, используется кросс-валидация или OOB ошибка. Объясните преимущества и недостатки OOB ошибки по сравнению с кросс-валидацией.

Ответ

Для прогнозирования факта подключения к маркетплейсу использованы четыре метода: логистическая регрессия, метод k ближайших соседей (kNN), случайный лес и градиентный бустинг. Логистическая регрессия и kNN применялись с предварительным масштабированием признаков.

Метод	Исходные гиперпараметры	Подобранные гиперпараметры	Train (исх.)	CV (исх.)	Test (исх.)	Train (тюн.)	CV (тюн.)	Test (тюн.)
Логистическая регрессия	C=1.0	C=0.01	0.673	0.665	0.640	0.671	0.669	0.644
kNN	k=5, uniform	k=31, uniform	0.745	0.618	0.680	0.689	0.665	0.656
Случайный лес	n=100, depth=None, leaf=1	n=200, depth=3, leaf=1	1.000	0.598	0.664	0.689	0.681	0.666
Градиентный бустинг	n=100, lr=0.1, depth=3	n=100, lr=0.03, depth=3	0.745	0.658	0.686	0.710	0.677	0.698

Таблица 3. Точность классификаторов до и после тюнинга гиперпараметров

Доля подключённых к маркетплейсу бизнесов в данных составляет около 45%. Если бы классификатор всегда предсказывал отсутствие подключения (тривиальный прогноз по самому частому классу), его точность на тестовой выборке равнялась бы примерно 0.55. Все четыре модели показывают точность, уверенно превышающую этот порог. Это свидетельствует о том, что в наборе признаков действительно присутствует полезный сигнал, позволяющий предсказывать факт подключения.

Интерпретация: при использовании исходных гиперпараметров, заданных без специального подбора, некоторые модели демонстрируют выраженные признаки переобучения. Наиболее заметен этот эффект у случайного леса. При неограниченной глубине деревьев он достигает идеальной точности на обучающей выборке (Train = 1.000), тогда как его кросс-валидационная точность оказывается самой низкой среди всех методов (0.598), а тестовая составляет лишь 0.664. Столь большой разрыв между обучающей и проверочными выборками - классический симптом переобучения: модель запоминает шум вместо выделения устойчивых закономерностей. Менее выраженно та же проблема проявляется у kNN с малым числом соседей ($k = 5$): точность на обучении равна 0.745 при кросс-валидационной точности 0.618.

Подбор гиперпараметров на основе кросс-валидации заметно улучшает обобщающую способность именно у тех моделей, которые были склонны к переобучению. Для случайного леса ограничение максимальной глубины деревьев до трёх поднимает кросс-валидационную точность с 0.598 до 0.681, а тестовую - до 0.666. Для kNN увеличение числа соседей до 31 повышает кросс-валидационную точность с 0.618 до 0.665. Для логистической регрессии и градиентного бустинга, изначально менее склонных к переобучению, тюнинг даёт лишь незначительный прирост. После подбора гиперпараметров разрыв между точностью на обучающей и тестовой выборках у всех моделей становится малым - в пределах 0.01–0.03. Это говорит об отсутствии существенного переобучения после настройки. Кросс-валидационные и тестовые оценки при этом близки друг к другу, что подтверждает надёжность кросс-валидации как инструмента оценки обобщающей способности моделей.

Итоговое упорядочение моделей по тестовой точности выглядит следующим образом. Наилучший результат показывает градиентный бустинг (0.698). За ним следуют случайный

лес (0.666) и kNN (0.656). Логистическая регрессия оказывается наименее точной среди четырёх методов (0.644). Это согласуется с заложенным процессом генерации данных: склонность к подключению нелинейна (квадратичный эффект возраста и взаимодействие инструмента с пригодностью продукции для онлайн-торговли), поэтому ансамблевые методы, гибко улавливающие нелинейности и взаимодействия, обыгрывают линейную модель, неспособную учесть их без явной спецификации.

Подбор гиперпараметров случайного леса по out-of-bag ошибке привёл к тому же набору параметров и той же тестовой точности, что и кросс-валидация (Таблица 4); сами внутренние оценки (OOB 0.683 и CV 0.681) практически совпали.

Подход	Гиперпараметры	Внутренняя оценка	Test acc
ООВ-подбор	n=200, depth=3, leaf=1	OOB acc = 0.683	0.666
CV-подбор	n=200, depth=3, leaf=1	CV acc = 0.681	0.666

Таблица 4. Случайный лес: подбор по OOB-ошибке и кросс-валидации

Преимущество OOB-подхода - вычислительная экономичность: out-of-bag наблюдения формируются в ходе бэггинга, без отдельных проходов кросс-валидации. Недостатки: метод применим только к бэггинговым алгоритмам (случайный лес), его оценка может быть более шумной на малых выборках и менее гибко обобщается на произвольные метрики качества по сравнению с кросс-валидацией.

Задание 3.3

Повторите предыдущий пункт, используя любой альтернативный критерий качества модели. Обоснуйте возможные преимущества и недостатки этого альтернативного критерия.

Повышенная сложность: дополнительно самостоятельно запрограммируйте не представленный в стандартных библиотеках критерий качества и используйте его для тюнинга гиперпараметров. Сравните результат стандартного и вашего критериев, а также опишите его преимущества и недостатки: в каких случаях его разумно применять, а в каких случаях он может оказаться не очень полезен.

Ответ

В качестве альтернативного критерия качества выбрана F1-мера - гармоническое среднее точности (precision) и полноты (recall) по классу подключившихся бизнесов. В отличие от ассигасы, использованной в задании 3.2, F1-мера не «вознаграждается» за простое угадывание преобладающего класса и сосредоточена на качестве распознавания целевого (положительного) класса. Метрика ROC-AUC здесь намеренно не используется, поскольку ей посвящён следующий пункт 3.4.

Метод	Исходные гиперпараметры	Подобранные гиперпараметры	F1 train (исх.)	F1 CV (исх.)	F1 test (исх.)	F1 train (тюн.)	F1 CV (тюн.)	F1 test (тюн.)
Логистическая регрессия	C=1.0	C=1	0.585	0.574	0.521	0.585	0.574	0.521
kNN	k=5, uniform	k=21, uniform	0.710	0.567	0.626	0.647	0.592	0.588
Случайный лес	n=100, depth=None, leaf=1	depth=5, leaf=5, n=200	1.000	0.546	0.622	0.611	0.583	0.568
Градиентный бустинг	n=100, lr=0.1, depth=3	lr=0.1, depth=2, n=100	0.690	0.582	0.620	0.628	0.594	0.620

Таблица 5. Качество классификаторов по F1-мере до и после тюнинга гиперпараметров

Значения F1-меры численно ниже значений ассигасы. Это объясняется тем, что F1-мера не учитывает корректно классифицированные отрицательные наблюдения (истинные «не подключившиеся»), а оценивает качество только по положительному классу. Признаки переобучения у исходных моделей отчётливо видны и по этому критерию: случайный лес с неограниченной глубиной даёт F1 = 1.000 на обучающей выборке при F1 = 0.546 на кросс-валидации. Подбор по F1 выбирает иные гиперпараметры, чем подбор по ассигасы в 3.2: для

логистической регрессии $C = 1$ вместо 0.01, для случайного леса - более гибкую конфигурацию ($depth = 5$, $leaf = 5$) вместо $depth = 3$, для градиентного бустинга - $depth = 2$ вместо $depth = 3$. Это наглядно показывает, что выбор критерия качества напрямую влияет на результат тюнинга.

Преимущества: F1-мера информативнее ассигасу при дисбалансе классов и в задачах, где важно качество распознавания именно целевого класса; её нельзя «обмануть» тривиальным прогнозом большинства, поскольку она одновременно требует высокой точности и полноты.

Недостатки: F1-мера полностью игнорирует истинно отрицательные исходы, зависит от выбранного порога классификации (здесь 0.5), сворачивает в одно число компромисс между precision и recall (взвешивая их одинаково, что не всегда отражает экономические приоритеты) и менее устойчива на малых выборках.

Повышенная сложность

Для тюнинга дополнительно запрограммирована собственная метрика NetValue, отсутствующая в стандартных библиотеках. Она задаёт асимметричные издержки ошибок: каждому верному прогнозу присваивается ценность +1, ложному срабатыванию (FP) - штраф -2, пропуску (FN) - штраф -1; итоговая величина усредняется по выборке. Такая структура отражает ситуацию, когда ошибочное действие на основании ложноположительного прогноза обходится дороже, чем упущенная возможность.

Метод	Подобранные гиперпараметры (по NetValue)	CV NetValue	Test NetValue	Test ACC
Логистическая регрессия	$C=0.01$	0.241	0.186	0.644
kNN	$k=31$, uniform	0.203	0.174	0.656
Случайный лес	$depth=3$, $leaf=1$, $n=200$	0.279	0.252	0.666
Градиентный бустинг	$lr=0.03$, $depth=2$, $n=100$	0.251	0.282	0.676

Таблица 6. Тюнинг по собственной метрике NetValue ($TP=+1$, $TN=+1$, $FP=-2$, $FN=-1$)

Подбор по NetValue выбирает гиперпараметры, близкие к подбору по ассигасу (в частности, для логистической регрессии вновь $C = 0.01$, для случайного леса - $depth = 3$), и заметно отличающиеся от подбора по F1. Лучшей по NetValue оказывается модель градиентного бустинга ($Test\ NetValue = 0.282$). Преимущество собственной метрики в том, что она напрямую кодирует экономическую ценность различных типов ошибок и согласует тюнинг с реальной ценой решений, а не с абстрактной статистической величиной; это особенно полезно, когда издержки ошибок известны и существенно различаются (как в нашей задаче, детально рассматриваемой в п. 3.7). Малые абсолютные значения NetValue объясняются её шкалой: при заданных весах идеальный классификатор даёт +1.0, стратегия "никого не подключать" - около +0.12, а "подключать всех" - около -0.67. Полученные 0.25–0.28 более чем вдвое превышают пассивный ориентир, то есть модели создают положительную чистую ценность.

Недостатки: метрика требует явного задания весов издержек (субъективный выбор), зависит от порога классификации, несопоставима между исследованиями и при неверной спецификации издержек может уводить тюнинг в ложном направлении. Поэтому её разумно применять при наличии обоснованной модели издержек, тогда как для оценки чистой различающей способности модели или при неизвестных издержках предпочтительнее стандартные метрики.

Задание 3.4

Постройте ROC-кривые для ваших моделей (с подобранными гиперпараметрами) и сравните их по AUC на тестовой выборке. Обсудите преимущества и недостатки AUC в сравнении с ACC в контексте вашей содержательной задачи.

Ответ

Для всех четырёх моделей с подобранными по ассигасу гиперпараметрами построены ROC-кривые на тестовой выборке (Рисунок 2). ROC-кривая отражает соотношение доли истинно положительных прогнозов (TPR) и доли ложно положительных прогнозов (FPR) при возможных порогах классификации. Площадь под ROC-кривой (AUC) численно характеризует способность модели ранжировать наблюдения по вероятности подключения к маркетплейсу.




Рисунок 2. ROC-кривые классификаторов на тестовой выборке

Все ROC-кривые лежат заметно выше диагонали случайного классификатора ($AUC = 0.5$), то есть каждая модель обладает реальной различающей способностью. По площади под кривой модели упорядочиваются следующим образом: градиентный бустинг ($AUC = 0.756$) превосходит случайный лес (0.750), kNN (0.733) и логистическую регрессию (0.713). Лучшей моделью стабильно оказывается градиентный бустинг, худшей - логистическая регрессия (что согласуется с нелинейностью процесса генерации данных).

Ключевое плюс в том, что ассигасу измеряет долю верных прогнозов при одном фиксированном пороге, тогда как ROC-AUC по построению инвариантен к соотношению классов: TPR и FPR нормируются внутри своих классов, поэтому изменение доли положительных не искажает оценку (в отличие от ассигасу, которую при дисбалансе перетягивает преобладающий класс). Следует оговориться, что при сильном дисбалансе ROC-AUC может быть излишне оптимистичным, и тогда информативнее precision-recall кривая; однако в нашем случае классы близки к сбалансированным, поэтому ROC-AUC применим.

С другой стороны, недостаток AUC в том, что она не отражает качество прогнозов в конкретной рабочей точке: модель с более высоким AUC может уступать при фактически используемом пороге, а агрегирование по всем порогам способно маскировать слабость модели в практически значимой области FPR. Ассигасу, напротив, напрямую интерпретируема и привязана к конкретному решающему правилу, но чувствительна к порогу и к дисбалансу классов. Поэтому для отбора модели по её различающей способности предпочтительнее AUC, а для оценки итогового качества решений при выбранном пороге - ассигасу.

Задание 3.5

Для любой модели (на ваш выбор) постройте матрицу ошибок на тестовой выборке при стандартном пороге классификации 0.5. Обсудите, какие ошибки встречаются чаще и с чем это может быть связано.

Ответ




Рисунок 3. Матрица ошибок (градиентный бустинг, порог 0.5)

Матрица ошибок построена для лучшей по результатам анализа модели - градиентного бустинга - при стандартном пороге классификации 0.5 на тестовой выборке из 500 наблюдений. Результаты представлены на Рисунке 3.

При пороге 0.5 модель допускает 96 ложноотрицательных ошибок (FN) и лишь 55 ложноположительных (FP). Таким образом, пропуски действительно подключившихся бизнесов происходят заметно чаще, чем ложные тревоги. Во-первых, класс подключившихся является меньшинством (около 45% выборки), поэтому при нейтральном

пороге 0.5 модель склонна чаще относить наблюдения к преобладающему классу «не подключён». Во-вторых, различающая способность модели умеренная ($AUC \approx 0.76$), поэтому значительная часть истинных подключений получает оценку вероятности ниже 0.5: полнота (recall) при этом пороге составляет лишь 0.566, тогда как точность (precision) выше - 0.694. Иными словами, при пороге 0.5 модель ведёт себя консервативно, отдавая приоритет надёжности положительных прогнозов в ущерб охвату подключившихся.

Задание 3.6

Для модели из предыдущего пункта рассмотрите не менее двух порогов, отличных от 0.5, и рассчитайте для каждого ACC, Precision и Recall. Обсудите, как изменение порога влияет на распределение ошибок разного типа, какие ошибки более существенны в контексте экономической задачи, и какой из порогов предпочтительнее.

Ответ

Для градиентного бустинга рассмотрены три порога классификации - 0.3, 0.5 и 0.7. Метрики качества и число ошибок каждого типа на тестовой выборке приведены в Таблице 7.

Порог	ACC	Precision	Recall	FP (ложные тревоги)	FN (пропуски)
0.3	0.602	0.529	0.910	179	20
0.5	0.698	0.694	0.566	55	96
0.7	0.646	0.762	0.290	20	157

Таблица 7. Метрики качества при разных порогах классификации (градиентный бустинг)

Снижение порога до 0.3 резко повышает полноту ($recall = 0.910$): модель улавливает почти всех подключившихся, но ценой роста числа ложных тревог ($FP = 179$) и падения точности ($precision = 0.529$). Повышение порога до 0.7, наоборот, повышает точность ($precision = 0.762$) и сокращает ложные тревоги ($FP = 20$), но резко увеличивает пропуски ($FN = 157$, $recall = 0.290$). Таким образом, порог регулирует баланс между ошибками первого и второго рода: чем он ниже, тем больше ложноположительных и меньше ложноотрицательных прогнозов, и наоборот.

В экономической постановке задачи прогноз используется для адресного воздействия на те компании, которые, согласно предсказанию, подключатся к маркетплейсу. Ложноположительное срабатывание (FP) оборачивается напрасной тратой ресурса на стимулирование бизнеса, который в действительности не станет подключаться. Ложноотрицательный прогноз (FN) означает упущенную возможность, которая, однако, не требует прямых затрат. Поскольку прямые издержки ложной тревоги, как правило, выше, чем цена пропуска (эта асимметрия формализована в собственной метрике NetValue, п. 3.3), из двух отличных от 0.5 порогов предпочтительнее более высокий порог 0.7: он минимизирует дорогостоящие ложные срабатывания и обеспечивает наибольшую точность прогнозов. Окончательный выбор оптимального порога на основе явной функции прибыли выполнен в задании 3.7.

Задание 3.7

Обсудите прикладную задачу, для решения которой может использоваться ваша классификационная модель. Опишите конкретного экономического агента (заказчика), который может быть заинтересован в использовании ваших прогнозов. Укажите, какие действия целесообразно предпринимать заказчику в зависимости от того, является ваш прогноз положительным или отрицательным. Исходя из этих действий и содержательных соображений предположите цены различных видов прогнозов. Руководствуясь критерием максимизации прибыли на обучающей выборке, выберите оптимальный порог прогнозирования для каждого из методов и сравните прибыли на тестовой выборке при соответствующих порогах. Результат представьте в форме таблицы, в которой должны быть указаны прибыли на тестовой выборке.

Проинтерпретируйте полученный результат, в частности, объяснив, как подобранное на данных оптимальное значение порога соотносится с экономической интуицией.

Повышенная сложность: предложите, содержательно обоснуйте и примените собственную, отличную от линейной функцию прибыли от прогнозов.

Ответ

В роли заказчика выступает команда развития маркетплейса (или отдел партнёрских программ платформы), которая проводит адресную кампанию по привлечению малого бизнеса: платное сопровождение онбординга, персональные консультации и помощь в размещении товаров. Прогноз модели используется для решения, на какие бизнесы тратить ограниченный бюджет кампании. При положительном прогнозе заказчик инвестирует в адресное сопровождение этого бизнеса; при отрицательном - не расходует ресурс.

Исходя из этих действий заданы условные ценности прогнозов (в тыс. руб. на один бизнес). Верный положительный прогноз (TP) приносит +10: заказчик сопровождает реально подключающийся бизнес и получает комиссионный доход за вычетом затрат на сопровождение. Ложноположительный прогноз (FP) даёт -5: ресурс на сопровождение потрачен, а бизнес не подключился. Ложноотрицательный (FN) и верный отрицательный (TN) оцениваются в 0: заказчик не предпринимает действий и не несёт прямых затрат. Итоговая прибыль на выборке равна $10 \cdot TP - 5 \cdot FP$. Оптимальный порог подобран максимизацией прибыли на обучающей выборке для каждого метода; прибыли на тестовой выборке приведены в Таблице 8.

Метод	Опт. порог (train)	Прибыль test (опт. порог)	Прибыль test (порог 0.5)
Логистическая регрессия	0.40	1085	685
kNN	0.30	1130	835
Случайный лес	0.38	1200	740
Градиентный бустинг	0.31	1140	975

Таблица 8. Прибыль на тестовой выборке при оптимальном пороге (линейная функция прибыли)

Оптимальные пороги всех методов лежат в диапазоне 0.30–0.40, то есть заметно ниже стандартного 0.5, и близки к теоретическому значению порога безубыточности $p^* = \frac{C_{FP}}{V_{TP} + C_{FP}} = \frac{5}{10+5} \approx 0.333$. Экономическая интуиция: заказчику выгодно сопровождать бизнес всякий раз, когда ожидаемая выгода превышает ожидаемые издержки, то есть когда вероятность подключения превышает порог безубыточности; поскольку выигрыш от верного попадания (10) вдвое больше цены ошибки (5), выгодно воздействовать даже на бизнесы с умеренной вероятностью подключения, чем и объясняется порог ниже 0.5. Подбор порога по прибыли существенно повышает итоговый результат по сравнению с наивным порогом 0.5 (например, для случайного леса 1200 против 740). По прибыли лучшим оказывается случайный лес (1200), что показывает: ранжирование методов по экономическому критерию может слегка отличаться от ранжирования по ассигасу или AUC. Предположение о постоянной ценности подключения упрощает реальную картину: комиссионный доход платформы обычно растёт вместе с масштабом бизнеса. Поэтому предложена нелинейная (гетерогенная) функция прибыли, в которой ценность верного положительного прогноза пропорциональна размеру компании: $TP_i = 2 \cdot \text{EmployeeCount}_i$, а цена ложного срабатывания остаётся фиксированной и равна -5.

Метод	Опт. порог (train)	Прибыль test (опт. порог)
Логистическая регрессия	0.40	1265
kNN	0.30	1310
Случайный лес	0.38	1322
Градиентный бустинг	0.36	1312

Таблица 9. Прибыль на тестовой выборке при нелинейной функции прибыли ($TP_i = 2 \cdot \text{EmployeeCount}_i$)

При учёте размера бизнеса абсолютные прибыли возрастают (лучший результат у случайного леса - 1322), а оптимальные пороги остаются в том же диапазоне 0.30–0.40. Содержательно такая функция точнее отражает экономику платформы, для которой привлечение крупного продавца ценнее привлечения мелкого, и потому усиливает приоритет адресного воздействия на более крупные бизнесы.

Задание 3.8

Опишите предполагаемые связи между переменными в форме DAG. Обучите структуру байесовской сети на обучающей выборке и сравните точность прогнозов вашего и обученного DAG на тестовой выборке.

Повышенная сложность: постройте ROC-кривую для байесовской сети и сравните её AUC с другими методами.

Ответ

Предполагаемая структура связей соответствует процессу генерации данных (Рисунок 4). Ненаблюдаемая способность U влияет и на подключение D , и на выручку Y , порождая эндогенность; инструмент Z (PilotVoucher) влияет только на D ; контрольные переменные (BusinessAge, EmployeeCount, OnlineSuitable) влияют как на D , так и на Y ; само подключение D влияет на выручку Y .




Рисунок 4. Предполагаемый DAG процесса генерации данных (U - ненаблюдаемая)

Для задачи классификации используется подграф над наблюдаемыми переменными: четыре признака (PilotVoucher, BusinessAge, EmployeeCount, OnlineSuitable) как родители переменной воздействия D . Непрерывные признаки дискретизированы по квартилям, параметры сети оценены байесовским методом. Затем структура сети обучена на тех же данных алгоритмом восхождения к вершине с критерием BIC. Сравнение точности приведено в Таблице 10.

DAG	Рёбра	ACC test	AUC test
Наш DAG	все 4 признака $\rightarrow D$	0.656	0.704
Обученный DAG (HillClimb + BIC)	PilotVoucher $\rightarrow D$, OnlineSuitable $\rightarrow D$	0.656	0.690

Таблица 10. Сравнение заданного и обученного DAG на тестовой выборке

Обе сети дают одинаковую точность (0.656). Алгоритм обучения структуры связал с переменной воздействия только два самых сильных признака - инструмент PilotVoucher и пригодность продукции OnlineSuitable, - отбросив BusinessAge и EmployeeCount, чьи связи с D слабее (критерий BIC штрафует избыточную сложность). Ориентация найденных рёбер ($D \rightarrow$ PilotVoucher, $D \rightarrow$ OnlineSuitable) обратна причинной, однако это марковски-

эквивалентное представление с той же предсказательной силой. Результат схож с корреляционной матрицей, где именно Z и OnlineSuitable сильнее всего связаны с D, а BusinessAge имеет почти нулевую линейную корреляцию. Наш DAG сохраняет небольшое преимущество по AUC (0.704 против 0.690) за счёт включения EmployeeCount, дающего слабый дополнительный сигнал для ранжирования.

Площадь под ROC-кривой (AUC) байесовской сети, построенной в соответствии с нашим DAG, составляет 0.704. Этот результат ниже, чем у всех четырёх рассмотренных ранее методов. Отставание объясняется двумя причинами: дискретизация непрерывных признаков приводит к потере части информации, а структура сети с условной независимостью признаков при заданном D (наивная структура) ограничивает способность улавливать взаимодействия, которые гибко моделируются ансамблевыми методами.

Задание 3.9

На основании проделанного анализа выберите лучший и худший из обученных классификаторов. Обсудите полученный результат. Критерий выбора необходимо сформулировать самостоятельно.

Ответ

В качестве основного критерия качества выбрана площадь под ROC-кривой (AUC) на тестовой выборке, а в качестве вспомогательного (для разрешения близких случаев) - accuracy. Такой выбор обоснован тем, что AUC не зависит от порога классификации и от баланса классов и характеризует фундаментальную способность модели ранжировать бизнесы по склонности к подключению, которая лежит в основе всех последующих решений (выбор порога, оценка прибыли). Сводные значения метрик на тестовой выборке приведены в Таблице 11.

Метод	Test ACC	Test F1	Test AUC
Логистическая регрессия	0.644	0.514	0.713
kNN	0.656	0.578	0.733
Случайный лес	0.666	0.530	0.750
Градиентный бустинг	0.698	0.623	0.756

Таблица 11. Сводное качество классификаторов на тестовой выборке

Лучшей моделью является градиентный бустинг: он одновременно лидирует по всем трём метрикам - AUC (0.756), accuracy (0.698) и F1 (0.623). Худшей моделью является логистическая регрессия, уступающая по всем метрикам (AUC 0.713, accuracy 0.644, F1 0.514). Результат устойчив: ранжирование совпадает независимо от выбранной метрики, что повышает доверие к выводу. Содержательно он объясняется природой процесса генерации данных: склонность к подключению нелинейна (квадратичный эффект возраста, взаимодействие инструмента с пригодностью продукции), и ансамблевые методы на деревьях, автоматически улавливающие нелинейности и взаимодействия, превосходят линейную логистическую регрессию, которая без явного добавления таких членов их не учитывает. Небольшое превосходство градиентного бустинга над случайным лесом можно объяснить тем, что бустинг последовательно обучает деревья на ошибках предыдущих моделей и тем самым эффективнее использует слабые закономерности в данных. В рассматриваемой задаче это позволяет несколько лучше учитывать сложные нелинейные зависимости и взаимодействия признаков, чем усреднение независимых деревьев в случайном лесе.

Задание 3.10 (повышенная сложность)

Включите в анализ дополнительный метод классификации, не рассматривавшийся в курсе и не представленный в библиотеке scikit-learn. Опишите его, осуществите тюнинг гиперпараметров и сопоставьте точность на тестовой выборке с точностью лучшего из обученных ранее методов.

Ответ

В качестве дополнительного метода выбран CatBoost - реализация градиентного бустинга на решающих деревьях, не входящая в библиотеку scikit-learn. От классического градиентного бустинга его отличают две ключевые идеи. Во-первых, упорядоченный бустинг: для оценки градиента на каждом объекте используются модели, обученные без участия этого объекта (на основе случайных перестановок), что снижает смещение прогнозов и переобучение. Во-вторых, CatBoost эффективно обрабатывает категориальные признаки напрямую, без необходимости ручного кодирования. Кроме того, симметричные деревья: на каждом уровне дерева применяется одно и то же условие разбиения, что действует как регуляризация и ускоряет обучение и инференс.

К преимуществам CatBoost относятся высокое качество на табличных данных «из коробки», устойчивость к переобучению, встроенная работа с категориальными переменными и малая потребность в ручной настройке гиперпараметров. Недостатки: более длительное обучение по сравнению с простыми моделями, меньшая интерпретируемость и избыточность для задач с небольшим числом признаков. Тюнинг проводился по глубине дерева, темпу обучения и числу итераций. Сравнение с лучшим из ранее обученных методов (градиентным бустингом) приведено в Таблице 12.

Метод	Подобранные гиперпараметры	CV ACC	Test ACC	Test AUC
CatBoost	depth=2, lr=0.1, iterations=100	0.686	0.692	0.757
Градиентный бустинг (лучший)	lr=0.03, depth=3, n=100	0.677	0.698	0.756

Таблица 12. CatBoost против лучшего метода (градиентный бустинг) на тестовой выборке

CatBoost практически не отличается от лучшего ранее метода: Test AUC 0.757 против 0.756 у градиентного бустинга, а по точности расхождение разнонаправленное и в пределах шума - CatBoost чуть выше на кросс-валидации (CV ACC 0.686 против 0.677), градиентный бустинг чуть выше на тесте (Test ACC 0.698 против 0.692). То есть CatBoost сильно не превосходит градиентный бустинг на наших данных. Это закономерно: информативный сигнал в признаках умеренный и уже полностью улавливается обычным бустингом, поэтому более сложный алгоритм не даёт дополнительного прироста качества. Преимущества CatBoost (упорядоченный бустинг, обработка категорий) сильнее проявляются на больших и существенно категориальных наборах данных, которых в нашей синтетической задаче нет.

Раздел 4. Регрессия

Задание 4.1

Отберите признаки, которые могут быть полезны при прогнозировании целевой (зависимой) переменной. Не включайте в число этих признаков переменную воздействия.

Ответ

Целевой переменной в задаче регрессии является месячная выручка Revenue. В набор признаков включены четыре наблюдаемые переменные: контрольные BusinessAge, EmployeeCount, OnlineSuitable и инструмент PilotVoucher. Три контрольные переменные непосредственно влияют на выручку в процессе генерации данных и потому являются содержательно обоснованными предикторами. Инструмент PilotVoucher включён для полноты, однако его прямая связь с выручкой близка к нулю (корреляция ≈ 0.05), поскольку он влияет на выручку лишь косвенно - через факт подключения.

Из набора признаков исключены две переменные. Переменная воздействия MarketplaceAdoption (D) не включается в соответствии с условием задания; Ненаблюдаемая способность U исключается из всех моделей, поскольку по построению не наблюдается исследователем и отсутствует в доступном наборе данных. Важно отметить, что именно исключение сильнейших факторов (ненаблюдаемой U и причинно связанного D) делает прогнозирование выручки по наблюдаемым признакам объективно трудным, что отражено в результатах ниже.

Задание 4.2

Для каждого метода:

- Оцените RMSE и MAPE, используя произвольные значения гиперпараметров на обучающей выборке, тестовой выборке и с помощью кросс-валидации.
- С помощью кросс-валидации на обучающей выборке подберите оптимальные значения гиперпараметров.
- В одной таблице укажите исходные и подобранные значения гиперпараметров, а также RMSE и MAPE, рассчитанные на тестовой выборке и с помощью кросс-валидации (до и после тюнинга).
- Обсудите наличие или отсутствие признаков переобучения модели.

Проинтерпретируйте полученные результаты.

Повышенная сложность: подберите на обучающей выборке оптимальные значения гиперпараметров градиентного бустинга, ориентируясь на значение OOB (out-of-bag) ошибки. Сопоставьте гиперпараметры и точность на тестовой выборке для градиентного бустинга в зависимости от того, используется кросс-валидация или OOB ошибка

Ответ

Для прогнозирования выручки использованы четыре метода: метод наименьших квадратов (МНК), kNN, случайный лес и градиентный бустинг (МНК и kNN - с масштабированием признаков). Для ориентира отметим, что тривиальный прогноз средней выручкой даёт RMSE, равный стандартному отклонению выручки на тесте (≈ 358 тыс. руб.). Результаты приведены в Таблице 13.

Метрика	МНК	kNN	Случайный лес	Градиентный бустинг
Исходные гиперпар.	—	k=5	n=100, depth=None	n=100, lr=0.1, depth=3
Подобранные гиперпар.	—	k=31	depth=3, leaf=10, n=200	lr=0.03, depth=2, n=100
RMSE train (исх.)	368.6	327.5	156.9	304.9
RMSE CV (исх.)	366.9	396.4	420.6	387.1

Метрика	МНК	kNN	Случайный лес	Градиентный бустинг
RMSE test (исх.)	334.3	366.9	378.4	345.9
RMSE CV (тюн.)	366.9	371.2	371.7	371.5
RMSE test (тюн.)	334.3	331.5	337.3	336.6
MAPE train (исх.)	0.960	0.809	0.388	0.862
MAPE CV (исх.)	0.965	0.977	1.050	0.995
MAPE test (исх.)	0.997	1.071	1.065	1.022
MAPE CV (тюн.)	0.965	0.964	1.005	1.013
MAPE test (тюн.)	0.997	1.011	1.044	1.056

Таблица 13. Качество регрессионных моделей (RMSE и MAPE) до и после тюнинга

Все настроенные модели лишь незначительно превосходят тривиальный прогноз средней (RMSE test $\approx$ 331–337 против 358), а MAPE составляет около 100%. Это происходит из-за того, что выручка в основном определяется ненаблюдаемой способностью U и причинно связанным фактом подключения D, которые по условию исключены из признаков; оставшиеся наблюдаемые факторы объясняют лишь малую долю дисперсии сильно скошенной (логнормальной) выручки, чем и обусловлены высокие RMSE и MAPE. Признаки переобучения наиболее ярко проявляет случайный лес: при неограниченной глубине RMSE на обучающей выборке резко занижен (156.9) при наихудшей кросс-валидационной ошибке (420.6); ограничение глубины при тюнинге устраняет переобучение. В задаче прогнозирования выручки после исключения переменной воздействия D лучшие результаты показывают простые модели: kNN и метод наименьших квадратов. Ансамблевые методы не дают преимущества. Это прямо противоположно ситуации в задаче классификации и объясняется тем, что в оставшихся наблюдаемых признаках практически не содержится нелинейного сигнала, который могли бы использовать сложные алгоритмы.

Повышенная сложность:

Подбор числа итераций градиентного бустинга по out-of-bag улучшению (при subsample = 0.8) дал $n_estimators = 153$ с RMSE на тесте 335.7, что практически совпадает с результатом кросс-валидационного подбора ($n_estimators = 100$, RMSE 336.6). Как и в разделе классификации, ООВ-оценка согласуется с кросс-валидацией, будучи при этом вычислительно более экономичной.

Задание 4.3

На основании сделанного анализа выберите лучшую и худшую из обученных моделей. Обоснуйте сделанный выбор.

Ответ

В качестве основного критерия выбран RMSE на тестовой выборке (как прямой показатель точности прогноза в исходных единицах), вспомогательного - MAPE. Сводные значения (после тюнинга) приведены в Таблице 14.

Метод	RMSE test	MAPE test
kNN	331.5	1.011
МНК	334.3	0.997
Градиентный бустинг	336.6	1.056
Случайный лес	337.3	1.044

Таблица 14. Итоговое качество регрессионных моделей на тестовой выборке

Лучшей моделью по RMSE является kNN (331.5), худшей - случайный лес (337.3). Вместе с тем следует подчеркнуть, что различия между всеми методами малы и все они лишь незначительно превосходят тривиальный прогноз средней ($\approx$ 358). Содержательно это

означает, что после исключения ненаблюдаемой способности U и причинно связанного фактора подключения D наблюдаемые признаки несут слабый и преимущественно линейный сигнал, поэтому гибкие нелинейные методы (лес, бустинг) не имеют преимущества над простыми (kNN, МНК), а местами даже уступают им из-за большей склонности к переобучению на шуме. Этот вывод противоположен результату раздела классификации и отражает разную природу двух задач на наших данных.

Задание 4.4 (повышенная сложность)

Включите в анализ дополнительный метод регрессии, не рассматривавшийся в курсе и не представленный в библиотеке `scikit-learn`. Опишите его, осуществите тюнинг гиперпараметров и сопоставьте точность на тестовой выборке с точностью лучшего из обученных ранее методов.

Ответ

В качестве дополнительного метода использован `CatBoostRegressor` - реализация градиентного бустинга на решающих деревьях для задачи регрессии, не входящая в `scikit-learn`. Его ключевые особенности те же, что и в классификационной версии: упорядоченный бустинг, снижающий смещение прогноза за счёт обучения на перестановках, и симметричные деревья, действующие как регуляризация и ускоряющие обучение. Преимущества - высокое качество на табличных данных без обработки и устойчивость к переобучению; недостатки - более тяжёлое обучение и избыточность для простых задач. Тюнинг проводился по глубине, темпу обучения и числу итераций.

Метод	Подобранные гиперпараметры	CV RMSE	Test RMSE	Test MAPE
CatBoostRegressor	depth=2, lr=0.03, iterations=300	367.9	335.2	1.004
kNN (лучший)	k=31	-	331.5	1.011

Таблица 15. CatBoostRegressor против лучшего метода (kNN) на тестовой выборке

CatBoostRegressor показывает RMSE на тестовой выборке 335.2 и не смог превзойти KNN. Как и в задаче классификации, более сложный алгоритм не обеспечивает прироста качества. Информативный сигнал в наблюдаемых признаках ограничен и уже полностью используется простыми моделями, поэтому дополнительная гибкость CatBoost не приводит к улучшению результатов на данной задаче.

Раздел 5. Эффекты воздействия

При выполнении заданий раздела обучающая и тестовая выборки были объединены в одну общую выборку из 2000 наблюдений. В качестве исхода используется месячная выручка Revenue, в качестве переменной воздействия - MarketplaceAdoption, в качестве инструмента - PilotVoucher. Наблюдаемые контрольные переменные: BusinessAge, EmployeeCount и OnlineSuitable. Потенциальные исходы и потенциальные статусы воздействия используются только в пункте 5.2, где это допускается условиями задания.

Задание 5.1

Математически запишите выражения для ATE и LATE (с учетом специфики обозначений ваших переменных). Содержательно проинтерпретируйте, что они отражают в вашем исследовании.

Ответ

В разделе используются следующие обозначения: Y = Revenue - месячная выручка малого бизнеса; D = MarketplaceAdoption - индикатор подключения к маркетплейсу; Z = PilotVoucher - индикатор получения пилотного ваучера; X = (BusinessAge, EmployeeCount, OnlineSuitable) - наблюдаемые контрольные переменные. Потенциальные исходы $Y(1)$ и $Y(0)$ обозначают выручку бизнеса при подключении и без подключения к маркетплейсу. Потенциальные статусы $D(1)$ и $D(0)$ обозначают статус подключения при наличии и отсутствии ваучера.

Средний эффект воздействия задается выражением:

$$ATE = E[Y(1) - Y(0)] \quad (7)$$

В нашем исследовании он показывает, насколько в среднем изменилась бы месячная выручка малого бизнеса при подключении к маркетплейсу по сравнению со сценарием отсутствия подключения.

Локальный средний эффект воздействия задается выражением

$$LATE = E[Y(1) - Y(0) | D(1) > D(0)] \quad (8)$$

В данной постановке LATE относится к группе compliers, то есть к бизнесам, которые подключаются к маркетплейсу именно из-за получения ваучера PilotVoucher. Поэтому ATE описывает эффект для всей совокупности фирм, а LATE - эффект для той части фирм, чье поведение меняется под воздействием инструмента.

Задание 5.2

Используя симулированные вами, но недоступные в реальных данных потенциальные исходы, получите оценки среднего эффекта воздействия, условных средних эффектов воздействия и локального среднего эффекта воздействия. Для ATE и LATE результаты представьте в форме таблицы, а для CATE постройте гистограмму или ядерную оценку функции плотности. Проинтерпретируйте полученные значения.

Ответ

Поскольку данные являются синтетическими, в пункте 5.2 можно напрямую использовать потенциальные исходы $Y1$ и $Y0$, а также индикатор compliers. Индивидуальный эффект воздействия определяется как $ITE_i = Y_i(1) - Y_i(0)$. Среднее значение ITE по всем наблюдениям дает истинный ATE, а среднее среди compliers - истинный LATE.

Эффект	Оценка, тыс. руб.	Интерпретация
ATE	175.58	Средний эффект подключения к маркетплейсу для всех бизнесов.
LATE	158.86	Средний эффект для compliers: бизнесов, подключающихся из-за ваучера PilotVoucher.

Таблица 16. Истинные ATE и LATE по потенциальным исходам

Истинный ATE равен 175.58 тыс. руб., то есть в среднем подключение к маркетплейсу увеличивает месячную выручку бизнеса на эту величину. Истинный LATE равен 158.86 тыс. руб. и относится только к подчиняющимся фирмам. Доля compliers в выборке составляет 0.325, следовательно, инструмент изменяет решение о подключении примерно у трети наблюдений.

OnlineSuitable	CATE, тыс. руб.	Количество наблюдений
0	102.99	866
1	231.02	1134

Таблица 17. Истинный CATE по группам OnlineSuitable

Условный эффект воздействия зависит от пригодности продукта к онлайн-продажам. Для бизнесов с OnlineSuitable = 0 средний индивидуальный эффект равен 102.99 тыс. руб., тогда как для OnlineSuitable = 1 он равен 231.02 тыс. руб. Это соответствует логике генерации данных: подключение к маркетплейсу сильнее увеличивает выручку тех фирм, чьи товары или услуги лучше подходят для онлайн-канала. Распределение индивидуальных эффектов подключения представлено на Рисунке 5.




Рисунок 5. Распределение истинных индивидуальных эффектов воздействия

Распределение индивидуальных эффектов не вырождается в одну точку. Это означает, что эффект подключения неоднороден: разные фирмы получают различный прирост выручки от выхода на маркетплейс. Такая неоднородность важна для дальнейшей интерпретации CATE-методов.

Задание 5.3

Оцените средний эффект воздействия как разницу в средних по выборкам тех, кто получил и не получил воздействие. Опишите недостатки соответствующего подхода с учетом специфики рассматриваемой вами экономической проблемы.

Ответ

Наивная оценка эффекта строится как разница между средней выручкой фактически подключившихся бизнесов и средней выручкой бизнесов без подключения. Этот подход не использует ни контрольные переменные, ни инструмент, поэтому он корректен только при отсутствии систематических различий между группами $D = 1$ и $D = 0$.

Группа	Средняя Revenue, тыс. руб.	Количество наблюдений
D=1: MarketplaceAdoption = 1	570.87	895
D=0: MarketplaceAdoption = 0	206.07	1105

Таблица 18. Средняя выручка по группам фактического подключения

Метод	Оценка АТЕ, тыс. руб.	Истинный АТЕ, тыс. руб.	Смещение, тыс. руб.
Наивная разница средних	364.80	175.58	189.22

Таблица 19. Наивная оценка АТЕ и сравнение с истинным АТЕ

Распределение выручки по статусу подключения представлено на Рисунке 6.




Рисунок 6. Распределение выручки по группам фактического подключения: диаграммы размаха

Наивная разница средних равна 364.80 тыс. руб., что на 189.22 тыс. руб. выше истинного АТЕ. Причина заключается в эндогенности подключения. Ненаблюдаемая предпринимательская способность *EntrepreneurialAbility* повышает как вероятность подключения к маркетплейсу, так и выручку. Поэтому простое сравнение групп смешивает причинный эффект подключения и исходные различия между бизнесами.

Задание 5.4

Используя оценки, полученные лучшими из обученных ранее классификационных и регрессионных моделей, оцените средний эффект воздействия с помощью метода наименьших квадратов, условных математических ожиданий, взвешивания на обратные вероятности, метода, обладающего двойной устойчивостью, и двойного машинного обучения. Сравните результаты и назовите ключевую предпосылку этих методов.

Ответ

Для оценки среднего эффекта воздействия по наблюдаемым данным использованы метод наименьших квадратов, метод условных математических ожиданий (раздельные модели исхода для группы воздействия и контроля), взвешивание на обратные вероятности, метод с двойной устойчивостью и двойное машинное обучение - без инструментальной переменной. Вероятность назначения воздействия оценивалась градиентным бустингом,

модели исхода - методом k ближайших соседей. Обе модели обучались на признаках X без включения PilotVoucher в качестве инструмента.

Метод	Оценка АТЕ, тыс. руб.	Истинный АТЕ, тыс. руб.	Смещение, тыс. руб.
OLS / МНК	336.88	175.58	161.30
Conditional expectations / T-learner	339.47	175.58	163.89
IPW	313.75	175.58	138.17
Doubly robust / AIPW	339.97	175.58	164.38
DML без IV	342.23	175.58	166.64

Таблица 20. Оценки АТЕ по наблюдаемым данным: OLS, T-learner, IPW, AIPW и DML без IV

Показатель	Значение
$\min \hat{e}$	0.092
$\text{mean } \hat{e}$	0.448
$\max \hat{e}$	0.703

Таблица 21. Диагностика propensity score после обрезки

Все методы из Таблицы 20 дают оценки выше истинного среднего эффекта воздействия. Наименьшее смещение среди них имеет взвешивание на обратные вероятности: оценка равна 313,75 тыс. руб. при смещении 138,17 тыс. руб. Метод наименьших квадратов, отдельные модели исхода, метод с двойной устойчивостью и двойное машинное обучение (без инструментальной переменной) дают оценки в диапазоне 336,88–342,23 тыс. руб. Диагностика вероятностей назначения воздействия показывает отсутствие экстремальных значений: оценки $\hat{e}$ находятся в диапазоне от 0,092 до 0,703. Следовательно, завышение оценок не связано с технической нестабильностью взвешивания на обратные вероятности из-за вероятностей, близких к нулю или единице. Ключевая предпосылка этих методов — условная независимость воздействия после контроля за X. Она означает, что при заданных BusinessAge, EmployeeCount и OnlineSuitable факт подключения к маркетплейсу не должен быть связан с потенциальными исходами. В нашем процессе генерации данных эта предпосылка нарушена, потому что EntrepreneurialAbility остаётся ненаблюдаемой и влияет одновременно на D и Y. Поэтому даже гибкие модели машинного обучения не устраняют основное смещение: они приближают наблюдаемые зависимости, но не восстанавливают ненаблюдаемый фактор.

Задание 5.5

Оцените условные средние эффекты воздействия с помощью метода наименьших квадратов, S-learner, T-learner, метода трансформации классов и X-learner. Сравните результаты и обсудите, насколько в вашем случае мотивировано применение метода X-learner.

Ответ

В пункте 5.5 оцениваются индивидуальные условные эффекты CATE(X). Используются пять подходов: МНК с взаимодействиями, S-learner, T-learner, transformed outcome и X-learner. Эти методы позволяют получить не только средний эффект, но и распределение эффектов по наблюдениям. При этом они по-прежнему используют только наблюдаемые контролируемые признаки, поэтому для причинной интерпретации требуют условной независимости воздействия.

Метод	Средний CATE, тыс. руб.	Ст. откл.	Минимум	Медиана	Максимум
МНК с взаимодействиями	331.19	136.34	3.86	335.99	833.04
S-learner	334.71	146.11	75.51	310.05	769.88
T-learner	339.47	146.53	121.15	311.43	762.14
Transformed outcome	329.92	229.53	-494.40	295.77	1148.04

X-learner	340.57	138.56	136.18	317.19	753.48
-----------	--------	--------	--------	--------	--------

Таблица 22. Распределение оценок CATE по методам

Распределение оценок CATE по методам представлено на Рисунке 7.




Рисунок 7. Распределение оценок CATE по методам

Метод	OnlineSuitable	Средний CATE, тыс. руб.	Количество наблюдений
S-learner	0	224.92	866
S-learner	1	418.55	1134
T-learner	0	229.14	866
T-learner	1	423.73	1134
Transformed outcome	0	194.81	866
Transformed outcome	1	433.10	1134
X-learner	0	231.18	866
X-learner	1	424.12	1134
МНК с взаимодействиями	0	219.86	866
МНК с взаимодействиями	1	416.21	1134

Таблица 23. Средние CATE по OnlineSuitable

Все CATE-методы показывают более высокий средний эффект для OnlineSuitable = 1, чем для OnlineSuitable = 0. Это совпадает с содержательной логикой и с истинными CATE из пункта 5.2. Например, для X-learner средний CATE равен 231.18 тыс. руб. при OnlineSuitable = 0 и 424.12 тыс. руб. при OnlineSuitable = 1. Однако уровень оценок существенно выше истинных значений 102.99 и 231.02 тыс. руб. соответственно. Это указывает на то, что методы без инструмента улавливают не только причинный эффект, но и смещение из-за ненаблюдаемой способности предпринимателя.

Применение X-learner в данной задаче методически допустимо, но не является критически необходимым. Метод особенно полезен при сильном дисбалансе групп воздействия и контроля, тогда как в нашей выборке доля подключившихся составляет около 45%. Поэтому преимущество X-learner ограничено. Его оценка близка к T-learner и S-learner по среднему уровню, а основной вывод остается тем же: неоднородность эффекта распознается, но причинная величина эффекта завышается из-за эндогенности.

С прикладной точки зрения CATE-оценки могли бы использоваться маркетинговыми или государственными органами для таргетирования программ поддержки: в первую очередь

стоит направлять ваучеры бизнесам с большей ожидаемой отдачей от онлайн-канала. Но в реальном применении такие оценки требуют более строгой идентификации, поскольку без учета эндогенности они могут завышать ожидаемый результат программы.

Задание 5.6

Оцените локальный средний эффект воздействия с помощью двойного машинного обучения без инструментальной переменной и двойного машинного обучения с инструментальной переменной. Сопоставьте результаты и объясните различие между средним эффектом воздействия и локальным средним эффектом воздействия.

Ответ

В пункте 5.6 сравниваются DML без инструментальной переменной, DML-IV и простая Wald-IV оценка. Для DML-IV переменная PilotVoucher используется только как инструмент Z и не включается в набор контролей W. Контроли W состоят из BusinessAge, EmployeeCount и OnlineSuitable. Регрессором для $E[Y|W]$ выступает kNN, а классификатором для $E[D|W]$ и $E[Z|W]$ - градиентный бустинг.

Метод	Оценка LATE / эффекта, тыс. руб.	Истинный LATE, тыс. руб.	Отклонение, тыс. руб.
DML без IV	342.23	158.86	183.36
DML-IV	174.03	158.86	15.17
Wald-IV	136.47	158.86	-22.39

Таблица 24. Оценки LATE / эффекта: DML без IV, DML-IV и Wald-IV

Показатель	Значение
$E[D Z = 1]$	0.5834
$E[D Z = 0]$	0.3080
First stage: $E[D Z = 1] - E[D Z = 0]$	0.2754
$E[D Z = 1] - E[D Z = 0]$	37.5849
DML-IV denominator: $\sum(Z_res * D_res)$	143.9643

Таблица 25. Диагностика инструмента и first stage

DML без IV дает оценку 342.23 тыс. руб., что почти совпадает с оценками АТЕ без инструмента и существенно превышает истинный LATE. Это ожидаемый результат: DML без IV ортогонализует только наблюдаемые контроли, но не устраняет скрытую эндогенность. DML-IV дает оценку 174.03 тыс. руб., то есть отклоняется от истинного LATE на 15.17 тыс. руб. Простая Wald-IV оценка равна 136.47 тыс. руб. и отклоняется от истинного LATE на 22.39 тыс. руб.

Различие между АТЕ и LATE в этой задаче связано с тем, что инструмент меняет поведение не всех фирм. АТЕ относится ко всей совокупности бизнесов, а LATE - только к compliers, для которых получение ваучера приводит к подключению. Экономическая интерпретация DML-IV оценки состоит в следующем: среди фирм, которые подключаются к маркетплейсу из-за PilotVoucher, подключение связано с приростом месячной выручки примерно на 174.03 тыс. руб. Эта оценка ближе к истинному LATE, чем методы без инструмента, поскольку использует экзогенную вариацию в D.

Задание 5.7

Оцените средние эффекты воздействия и локальные средние эффекты воздействия, используя худшие из обученных классификационных и регрессионных моделей. Сопоставьте результаты с теми, что были получены с помощью лучших моделей. Сделайте вывод об устойчивости результатов к качеству используемых методов машинного обучения.

Ответ

Для проверки устойчивости оценки пересчитаны с использованием лучших и худших моделей из разделов классификации и регрессии. В качестве лучшего классификатора

использован градиентный бустинг, в качестве худшего - логистическая регрессия. В регрессионной задаче лучшей моделью был kNN, худшей - случайный лес.

Задача	Лучшая модель	Худшая модель
Propensity / классификация	Градиентный бустинг	Логистическая регрессия
Outcome / регрессия	kNN	Случайный лес

Таблица 26. Лучшие и худшие модели, используемые в задании 5.7

Эффект	Метод	Модели	Оценка	Истина	Отклонение	Классификатор	Регрессор
ATE	IPW	лучшие	313.75	175.58	138.17	Градиентный бустинг	kNN
ATE	DR / AIPW	лучшие	339.97	175.58	164.38	Градиентный бустинг	kNN
ATE	DML без IV	лучшие	342.23	175.58	166.64	Градиентный бустинг	kNN
LATE	DML-IV	лучшие	174.03	158.86	15.17	Градиентный бустинг	kNN
ATE	IPW	худшие	333.79	175.58	158.20	Логистическая регрессия	Случайный лес
ATE	DR / AIPW	худшие	343.17	175.58	167.59	Логистическая регрессия	Случайный лес
ATE	DML без IV	худшие	331.24	175.58	155.65	Логистическая регрессия	Случайный лес
LATE	DML-IV	худшие	167.66	158.86	8.80	Логистическая регрессия	Случайный лес

Таблица 27. Устойчивость ATE и LATE к выбору лучших и худших ML-моделей

Эффект	Метод	Лучшие	Худшие	Разница: лучшие - худшие, тыс. руб.
ATE	DML без IV	342.23	331.24	10.99
ATE	DR / AIPW	339.97	343.17	-3.20
ATE	IPW	313.75	333.79	-20.04
LATE	DML-IV	174.03	167.66	6.37

Таблица 28. Различия оценок между лучшими и худшими ML-моделями

Смена лучших моделей на худшие меняет оценки, но не меняет содержательный вывод. Методы ATE без IV остаются существенно выше истинного ATE как при лучших, так и при худших моделях. Например, DML без IV дает 342.23 тыс. руб. с лучшими моделями и 331.24 тыс. руб. с худшими. Различие между этими оценками равно 10.99 тыс. руб., тогда как смещение относительно истинного ATE остается более 150 тыс. руб. Следовательно, основная проблема связана не с качеством прогнозных моделей, а с нарушением идентификационной предпосылки.

DML-IV оказывается более устойчивым: оценка с лучшими моделями равна 174.03 тыс. руб., с худшими - 167.66 тыс. руб.; разница составляет 6.37 тыс. руб. Обе оценки остаются заметно ближе к истинному LATE 158.86 тыс. руб., чем оценки без инструмента. Это подтверждает, что использование инструментальной переменной в данной симуляции важнее, чем выбор конкретного ML-алгоритма для вспомогательных функций.

Задание 5.8

Резюмируйте ключевые выводы проведенного в данном разделе анализа.

Ответ

Эффект	Метод	Оценка эффекта, тыс. руб.	Интерпретация	Истинный эффект, тыс. руб.	Отклонение, тыс. руб.
ATE	Истинный ATE	175.58	истинный эффект	175.58	0.00
LATE	Истинный LATE	158.86	истинный эффект	158.86	0.00
ATE	Наивная разница средних	364.80	смещенная оценка без учета эндогенности	175.58	189.22
ATE	OLS	336.88	метод на условной независимости	175.58	161.30
ATE	Conditional expectations / T-learner	339.47	метод на условной независимости	175.58	163.89
ATE	IPW	313.75	метод на условной независимости	175.58	138.17
ATE	Doubly robust	339.97	метод на условной независимости	175.58	164.38
ATE	DML без IV	342.23	метод на условной независимости	175.58	166.64
LATE	DML-IV	174.03	инструментальный метод	158.86	15.17
LATE	DML-IV с худшими моделями	167.66	инструментальный метод	158.86	8.80

Таблица 29. Итоговые результаты раздела 5

Итоговое сравнение оценок эффектов представлено на Рисунке 8.




Рисунок 8. Сравнение основных оценок эффекта

Основной результат раздела состоит в том, что истинный эффект подключения к маркетплейсу положителен, но методы без инструментальной переменной систематически завышают его. Истинный средний эффект воздействия равен 175,58 тыс. руб., тогда как наивная разница средних равна 364,80 тыс. руб. Оценки метода наименьших квадратов, отдельных моделей исхода, взвешивания на обратные вероятности, метода с двойной устойчивостью и двойного машинного обучения (без инструментальной переменной) также остаются выше истинного среднего эффекта воздействия.

Причина завышения связана с эндогенностью MarketplaceAdoption. Более способные предприниматели чаще подключаются к маркетплейсам и одновременно получают

большую выручку. Наблюдаемые контроли частично описывают различия между бизнесами, но не содержат EntrepreneurialAbility. Поэтому методы, основанные на условной независимости после контроля за X, не дают корректной причинной оценки в данном процессе генерации данных.

Инструментальный подход даёт более согласованные результаты. Двойное машинное обучение с инструментальной переменной на лучших моделях даёт оценку 174,03 тыс. руб., а на худших — 167,66 тыс. руб.; обе оценки близки к истинному локальному среднему эффекту воздействия 158,86 тыс. руб. В данной постановке машинное обучение полезно для оценки вспомогательных функций, но само по себе не устраняет ненаблюдаемую эндогенность. Для причинной интерпретации эффекта подключения необходима корректная стратегия идентификации — в нашем случае использование инструмента PilotVoucher.

Задание 5.9

В случае необходимости проведите дополнительный анализ.

Ответ

В качестве дополнительного анализа проверены релевантность инструмента PilotVoucher и устойчивость IPW к экстремальным значениям вероятности назначения воздействия. Дополнительно сопоставлены DML-IV и простая Wald-IV оценка.

Показатель	Значение
Коэффициент при PilotVoucher в first stage	0.2879
t-statistic	13.8325
p-value	0.0000
F-statistic для инструмента	191.3372
$E[D Z = 1] - E[D Z = 0]$ без контролей	0.2754

Таблица 30. Проверка релевантности инструмента PilotVoucher

Регрессия первого этапа подтверждает релевантность инструмента. Коэффициент при PilotVoucher равен 0.2879, t-statistic равен 13.8325, F-statistic равен 191.3372. Разница $E[D|Z = 1] - E[D|Z = 0]$ без контролей составляет 0.2754. Следовательно, получение ваучера существенно повышает вероятность подключения к маркетплейсу.

Показатель	Значение
Использованный классификатор	Градиентный бустинг
min $e(W)$ до clipping	0.0919
1% квантиль $e(W)$	0.1081
5% квантиль $e(W)$	0.2214
mean $e(W)$	0.4475
95% квантиль $e(W)$	0.5973
99% квантиль $e(W)$	0.6929
max $e(W)$ до clipping	0.7030
Обрезано снизу (<0.01)	0
Обрезано сверху (>0.99)	0
Всего обрезано	0
Доля обрезанных наблюдений	0

Таблица 31. Sensitivity check для propensity score в IPW

Проверка вероятностей назначения воздействия показывает, что оценки вероятностей не принимают экстремальных значений. Минимальное значение $e(W)$ до clipping равно 0.0919, максимальное - 0.7030, количество обрезанных наблюдений равно нулю. Поэтому нестабильность IPW не является основной причиной смещения; смещение связано с ненаблюдаемой эндогенностью.

Метод	Оценка LATE, тыс. руб.	Разница с Wald-IV, тыс. руб.	Истинный LATE, тыс. руб.	Отклонение, тыс. руб.
DML-IV	174.03	37.57	158.86	15.17
Wald-IV	136.47	0.00	158.86	-22.39

Таблица 32. Сравнение DML-IV и простой Wald-IV оценки

DML-IV и Wald-IV используют одну и ту же инструментальную идею, но отличаются обработкой контролей и вспомогательных зависимостей. Wald-IV дает оценку 136.47 тыс. руб., DML-IV - 174.03 тыс. руб. В данной симуляции обе оценки существенно ближе к истинному LATE, чем методы без инструмента. При этом DML-IV лучше согласуется с истинным LATE, поскольку дополнительно учитывает наблюдаемые контроли W и использует cross-fitting для оценки вспомогательных функций.

Список литературы

1. Ramanathan, R., Ramanathan, U., & Hsiao, H.-L. (2012). The impact of e-commerce on Taiwanese SMEs: Marketing and operations effects. *International Journal of Production Economics*, 140(2), 934–943. <https://doi.org/10.1016/j.ijpe.2012.07.017>
2. Zhu, K., & Kraemer, K. L. (2005). Post-adoption variations in usage and value of e-business by organizations: Cross-country evidence from the retail industry. *Information Systems Research*, 16(1), 61–84. <https://doi.org/10.1287/isre.1050.0045>